

# Predicción de Energías Renovables como Series Temporales

Predicción

# Contents

- ① Regresión Lineal
- ② Modelos clásicos de predicción de ST
  - Modelos Autorregresivos
  - Modelos de Medias Móviles
  - Modelos Autorregresivos de Medias Móviles
- ③ Validación de modelos de ST
- ④ Modelo Autorregresivo Integrado de Medias Móviles
- ⑤ Modelo Autorregresivo Integrado de Medias Móviles Estacional
- ⑥ Variables Exógenas
- ⑦ Modelos de suavizado exponencial
- ⑧ Long Short Term Memory (LSTM)
- ⑨ Resumen

## Regresión Lineal

# Repaso: regresión lineal (I)

- ▶ También conocido como **mínimos cuadrados ordinarios** (OLS – Ordinary Least-Squares).
- ▶ Método más común para hacer aprendizaje estadístico.
- ▶ Variables predictivas ( $X$ ), salida ( $y$ ):

$$\hat{y} = \beta_0 + \beta_1 X$$

- ▶ Entrenamiento: buscar  $\beta_0$  y  $\beta_1$ .
  - ▶ Función de pérdida: mínimos cuadrados.

$$L(X) = \sum_{i=1}^N (y_i - \hat{y}_i)^2.$$

- ▶ Minimizamos la función de pérdida.

# Repaso: regresión lineal (II)

## ► Ventajas:

- Poco costoso computacionalmente.
  - Fácil de interpretar.
- 

## ► Inconvenientes:

- Es muy rígido.
- Probablemente no encuentre la relación real entre  $X$  e  $y$ .

## Modelos clásicos de predicción de ST

# Modelos clásicos de predicción de ST

- ▶ Modelos estadísticos sencillos.
- ▶ Se basan principalmente en la búsqueda de relaciones lineales.
- ▶ Bien aplicados pueden ser la mejor solución para predecir una ST.
- ▶ Modelos:
  - ▶ **Familia ARIMA**: AR, MA, ARMA, ARIMA, SARIMA
  - ▶ **Exponential Smoothing**: simple, damped, holt-winters

# Horizontes de predicción

## Horizonte de predicción

El **horizonte de predicción** es el número de intervalos de tiempo que llevamos sin conocer información real.

Train <sub>1</sub>	Train <sub>2</sub>	...	Train <sub>N</sub>	Test <sub>1</sub>	Test <sub>2</sub>	...	Test <sub>M</sub>
				$h=0$	$h=1$	...	$h=M$

- Es importante decidir el horizonte de predicción para el cual nos interesa predecir.



# Horizontes de predicción





Imagen obtenida de <https://www.sapanalytics.cloud/time-series-forecasting-smart-predict/>

# Modelos Autorregresivos: AR(p) (I)

- ▶ Modeliza el valor siguiente de la serie como una función lineal de las **observaciones** anteriores.
- ▶ Son modelos estacionarios.
- ▶ Parámetro: orden **p**
  - ▶ p es el número de retrasos que cogemos hacia atrás.



# Modelos Autorregresivos: AR(p) (II)

- ▶ Regresión lineal sobre los retrasos.
- ▶ Modelo:

$$X_t = C + \sum_{j=1}^p \phi_j X_{t-j} + \epsilon_t .$$

donde


- ▶  $C$  es una constante.
- ▶  $\phi_i$  coeficientes de la regresión lineal
- ▶  $\epsilon_i$  ruido blanco

# Modelos Autorregresivos: AR(p) (III)

- ▶ Elección del orden  $p$ :
  - ▶ ACF.
  - ▶ PACF (sobre esta es más sencillo ver patrones).
  - ▶ Búsqueda del mejor parámetro en un conjunto de validación.
- ▶ Búsqueda de coeficientes  $\phi_i$ :
  - ▶ Búsqueda por mínimos cuadrados (los que minimizan el error cuadrático).

# Modelos de Medias Móviles: MA(q) (I)

- ▶ Modelo de regresión sobre los **errores** de la serie temporal.
- ▶ Son siempre modelos estacionarios.
- ▶ Parámetro: orden **q**
  - ▶ q es el número de retrasos que cogemos de ruido hacia atrás.



# Modelos de Medias Móviles: MA(q) (II)

- ▶ Regresión lineal sobre los errores previos.
- ▶ Modelo:

$$X_t = \epsilon_t + \sum_{i=1}^q \theta_i \epsilon_{t-i} .$$

donde

- ▶  $\epsilon_k$  son variables aleatorias i.i.d. que siguen una normal (ruido blanco).
- ▶  $\theta_i$  son los coeficientes de la regresión.

# Modelos de Medias Móviles: MA( $q$ ) (III)

- ▶ Elección del orden  $q$ :
  - ▶ La gráfica ACF nos puede dar pistas.
  - ▶ Búsqueda del mejor parámetro en un conjunto de validación.
- ▶ Búsqueda de coeficientes  $\theta_i$ :
  - ▶ Es más complicado que en AR, porque no vemos los términos de error previos.
  - ▶ Se suelen usar procedimientos no lineales iterativos.

# Modelos Autorregresivos de Medias Móviles: ARMA(p, q) (I)

- ▶ Modeliza el siguiente valor de la serie como función lineal de las observaciones y los errores residuales.
- ▶ Combina **AR** y **MA**.
- ▶ Parámetros:
  - ▶ **p**: orden de AR.
  - ▶ **q**: orden de MA.
- ▶ Funciona para series sin tendencias ni componentes estacionales (ST estacionarias).



# Modelos Autorregresivos de Medias Móviles: ARMA(p, q) (II)

- ▶ Regresión lineal sobre los retrasos de la serie y los errores previos.
- ▶ Modelo:

$$X_t = C + \sum_{j=1}^p \phi_j X_{t-j} + \sum_{i=1}^q \theta_i \epsilon_{t-i} + \epsilon_t .$$

donde

- ▶  $\epsilon_k$ , son variables aleatorias i.i.d, obtenidas a partir de una gaussiana.
- ▶  $X_{t-k}$  son las observaciones anteriores de la serie.
- ▶  $\phi_k$  y  $\theta_k$  son los coeficientes de autorregresión y de medias móviles respectivamente.
- ▶  $C$  es una constante.

# Modelos Autorregresivos de Medias Móviles: ARMA(p, q) (III)

- ▶ Estimar el orden:
  - ▶ ACF, PACF (subjetivo, vemos a continuación cómo estimarlo)
  - ▶ Proceso de validación.
- ▶ Búsqueda de coeficientes:
  - ▶ Estimación por mínimos cuadrados.

# Función en Python



statsmodel

```
statsmodels.tsa.statespace.sarimax.SARIMAX(endog, exog=None, order=(1, 0, 0),  
      seasonal_order=(0, 0, 0, 0), trend=None, measurement_error=False,  
      time_varying_regression=False, mle_regression=True, simple_differencing=False,  
      enforce_stationarity=True, enforce_invertibility=True, hamilton_representation=False,  
      concentrate_scale=False, trend_offset=1, use_exact_diffuse=False, dates=None,  
      freq=None, missing='none', validate_specification=True, **kwargs)
```

**endog** La serie temporal.

**order** El orden del modelo, que en nuestro caso será **(p,0,q)**.

## Validación de modelos de ST

# Método de Box-Jenkins

Asumimos que si el proceso es estacionario se puede aproximar por ARMA.

Proceso iterativo, según se reciben nuevos datos:

- ❶ **Identificación.** Elegir un submodelo (definir  $p, q$ ) que resuma los datos.
  - ▶ AR: si en ACF hay una bajada gradual tras un tiempo  $p$ , que en PACF es una caída brusca.
  - ▶ MA: si en ACF tras un tiempo  $q$  hay una caída brusca.
  - ▶ AR+MA: si presenta los dos comportamientos
- ❷ **Estimación.** Búsqueda de coeficientes.
  - ▶ Método numérico para minimizar la función de pérdida.
  - ▶ Lo gestiona el método elegido en cuestión.
  - ▶ Ejemplos: ajuste por mínimos cuadrados, por máxima verosimilitud, BFGS,...
- ❸ **Comprobación.** Ver si el modelo se adecúa a los datos.
  - ▶ Overfitting
  - ▶ Los errores residuales deben seguir siendo gaussianos e independientes:
    - ▶ Usar histogramas, diagramas de densidad,...
    - ▶ ACF y PACF sobre los residuos.

# Método de Box-Jenkins: fase de Identificación

## MA( $q$ )

**ACF** Primeros  $q$  coefs significativos. Caída brusca a 0.

**PACF** Decrecimiento exponencial rápido u ondas sinusoidales.

## AR( $p$ )

Decrecimiento exponencial rápido u ondas sinusoidales.

Primeros  $p$  coefs significativos. Caída brusca a 0.

## ARMA( $p,q$ )

Comportamiento irregular, con  $q$  picos. Decaimiento posterior.

Decrece paulatinamente.

# Validación de modelos de ST

- ▶ En ST, como en cualquier modelo de Aprendizaje Automático, nos interesa validar la definición del modelo sobre datos no vistos en el entrenamiento  $\Rightarrow$  **conjunto de validación**.
- ▶ k-CV no se puede utilizar directamente en ST.
  - ▶ Perdemos la estructura temporal!
- ▶ **Backtesting** es el nombre que se utiliza en ST para el proceso de validación.

# Tipos de backtesting (I)

## División del train en train-validation

- ▶ Útil cuando tenemos muchos datos  $\Rightarrow$  train-validation representativo.
- ▶ Fijamos un porcentaje para la división: 50-50, 60-40,...

## División del train en múltiples conjuntos de train-validation

- ▶ Más costoso computacionalmente.
- ▶ Resultados más robustos.
- ▶ El conjunto de validación en todas las divisiones debe tener el mismo tamaño.



# Tipos de backtesting (II)

## Validación walk-forward

- ▶ Para validar modelos que se van a actualizar con frecuencia.
- ▶ Vemos la partición de train como una ventana.
- ▶ Establecemos:
  - ▶ Tamaño de la ventana inicial.
  - ▶ Si la ventana es corrida o se va ampliando.
- ▶ Es el método más robusto, pero evalúa muchos modelos (equivalente a LOOCV).

Notebook

Predicción utilizando Modelos Clásicos



## Modelo Autorregresivo Integrado de Medias Móviles

# Modelo Autorregresivo Integrado de Medias Móviles: ARIMA(p,d,q) (I)

- ▶ Generalización de ARMA.
- ▶ Combina **AR** y **MA**, pero calculados sobre la **serie de diferencias** de los datos indicados.
- ▶ Parámetros:
  - ▶ p: orden de AR.
  - ▶ d: grado de diferenciación.
  - ▶ q: orden de MA.
- ▶ Estimamos el orden por backtesting.

# Modelo Autorregresivo Integrado de Medias Móviles: ARIMA(p,d,q) (II)

► Modelo:

$$D_t = C + \sum_{j=1}^p \phi_j D_{t-j} + \sum_{i=1}^q \theta_i \epsilon_{t-i} + \epsilon_t .$$

donde

- $\epsilon_k$ , son variables aleatorias i.i.d, obtenidas a partir de una gaussiana.
- $D_{t-k}$  son los pasos anteriores de la serie de diferencias.
- $\phi_k$  y  $\theta_k$  son los coeficientes de autorregresión y de medias móviles respectivamente.
- $C$  es una constante.

# Función en Python



statsmodel

```
statsmodels.tsa.statespace.sarimax.SARIMAX(endog, exog=None, order=(1, 0, 0),
      seasonal_order=(0, 0, 0, 0), trend=None, measurement_error=False,
      time_varying_regression=False, mle_regression=True, simple_differencing=False,
      enforce_stationarity=True, enforce_invertibility=True, hamilton_representation=False,
      concentrate_scale=False, trend_offset=1, use_exact_diffuse=False, dates=None,
      freq=None, missing='none', validate_specification=True, **kwargs)
```

**endog** La serie temporal.

**order** El orden del modelo, que en nuestro caso será **(p,d,q)**.

Notebook

ARIMA



## Modelo Autorregresivo Integrado de Medias Móviles Estacional



# Modelo Autorregresivo Integrado de Medias Móviles Estacional: SARIMA(p,d,q)(P,D,Q,m) (I)

- ▶ Extensión de ARIMA que considera además periodos estacionales.
- ▶ Parámetros:
  - ▶ **Tendencias:**
    - ▶ p: orden de AR.
    - ▶ d: grado de diferenciación.
    - ▶ q: orden de MA.
  - ▶ **Estacionalidad:**
    - ▶ P: orden de AR para la parte estacional.
    - ▶ D: grado de diferenciación estacional.
    - ▶ Q: orden de MA para la parte estacional.
    - ▶ m: número de pasos para un periodo estacional.

# Modelo Autorregresivo Integrado de Medias Móviles Estacional: SARIMA(p,d,q)(P,D,Q,m) (II)

- ▶ **Problema:** son 7 parámetros!!
- ▶ Hay que hacer una búsqueda en rejilla, para encontrar la mejor configuración del modelo.
  - ▶ Mejor no hacerlo en un notebook.
  - ▶ Intentar agilizar cálculos utilizando varias CPUs en la medida de lo posible.

# Función en Python



statsmodel

```
statsmodels.tsa.statespace.sarimax.SARIMAX(endog, exog=None, order=(1, 0, 0),
      seasonal_order=(0, 0, 0, 0), trend=None, measurement_error=False,
      time_varying_regression=False, mle_regression=True, simple_differencing=False,
      enforce_stationarity=True, enforce_invertibility=True, hamilton_representation=False,
      concentrate_scale=False, trend_offset=1, use_exact_diffuse=False, dates=None,
      freq=None, missing='none', validate_specification=True, **kwargs)
```

**endog** La serie temporal.

**order** El orden del modelo, que en nuestro caso será **(p,d,q)**.

**seasonal\_order** El orden de la parte estacional, es decir, **(P,D,Q,m)**.

Notebook

SARIMA



Variables Exógenas

# Modelos Autorregresivos con Variables Exógenas

- ▶ A veces la ST no es suficiente para predecir valores futuros y necesitamos información extra.
- ▶ Este es el caso de la predicción de **energías renovables** como la eólica y la solar, donde conocer la meteorología (que es muy cambiante) ayuda a la predicción.
- ▶ Todos los modelos anteriores admiten variables exógenas:
  - ▶ **ARX, MAX, ARMAX, ARIMAX, SARIMAX.**

# Función en Python



statsmodel

```
statsmodels.tsa.statespace.sarimax.SARIMAX(endog, exog=None, order=(1, 0, 0),
      seasonal_order=(0, 0, 0, 0), trend=None, measurement_error=False,
      time_varying_regression=False, mle_regression=True, simple_differencing=False,
      enforce_stationarity=True, enforce_invertibility=True, hamilton_representation=False,
      concentrate_scale=False, trend_offset=1, use_exact_diffuse=False, dates=None,
      freq=None, missing='none', validate_specification=True, **kwargs)
```

**endog** La serie temporal.

**exog** Las variables exógenas.

**order** El orden del modelo, que en nuestro caso será **(p,d,q)**.

**seasonal\_order** El orden de la parte estacional, es decir, **(P,D,Q,m)**.

Notebook

SARIMAX





## Modelos de suavizado exponencial

# Modelos de Suavizado Exponencial (ETS)

- ▶ **Semejanzas** con modelos de la familia ARIMA:
    - ▶ Predicción es una suma ponderada de las observaciones anteriores.
  - ▶ **Diferencias** con modelos de la familia ARIMA:
    - ▶ Se utiliza un decaimiento exponencial de los pesos.
- 
- ▶ Diferentes modelos:
    - ▶ Suavizado exponencial simple.
    - ▶ Suavizado exponencial doble.
    - ▶ Suavizado exponencial triple.

# Suavizado Exponencial Simple (STS)

- ▶ Modelos aptos para ST sin tendencia ni estacionalidad.
- ▶ Parámetros:
  - ▶ Coeficiente de suavizado:  $\alpha \in [0, 1]$ .
    - ▶  $\alpha = 1$ , aprendizaje rápido,
    - ▶  $\alpha = 0$ , aprendizaje lento.
- ▶ Definición del modelo:

$$s_0 = x_0$$

$$s_t = \alpha x_t + (1 - \alpha)s_{t-1}.$$

# Suavizado Exponencial Doble

- ▶ Modelos que consideran explícitamente tendencias en la ST.
- ▶ Parámetros:
  - ▶ Coeficiente de suavizado:  $\alpha \in [0, 1]$ .
  - ▶ Coeficiente de suavizado de la tendencia:  $\beta \in [0, 1]$ .
- ▶ Definición del modelo (siguiendo un modelo aditivo):

$$F_{t+m} = s_t + mb_t$$

$$s_1 = x_1 ; b_1 = x_1 - x_0$$

$$s_t = \alpha x_t + (1 - \alpha)(s_{t-1} + b_{t-1})$$

$$b_t = \beta(s_t - s_{t-1}) + (1 - \beta)b_{t-1} .$$

# Suavizado Exponencial Triple (Holt-Winters ES)


- ▶ Modelos que consideran además estacionalidad en la ST.
- ▶ Son modelos adaptativos que modelan variaciones en el tiempo de la media, la tendencia y la estacionalidad.
- ▶ Parámetros:
  - ▶ Coeficiente de suavizado:  $\alpha \in [0, 1]$ .
  - ▶ Coeficiente de suavizado de la tendencia:  $\beta \in [0, 1]$ .
  - ▶ Coeficiente de suavizado de la estacionalidad:  $\gamma \in [0, 1]$ .

## Long Short Term Memory (LSTM)

# Redes Neuronales Recurrentes (I)

- ▶ La mayoría de modelos de ML asumen independencia entre los ejemplos.
- ▶ En la predicción de series temporales esta hipótesis no es cierta, y los patrones son muy dependientes del contexto.
- ▶ Las **Redes Neuronales Recurrentes (RNNs)** permiten conexiones hacia atrás entre neuronas, paliando este problema.
  - ▶ Valores producidos previamente por la red se introducen como entradas de nuevo en la red.
- ▶ Estas redes presentan dependencias entre los pesos por lo que requieren un entrenamiento especial (Back-propagation Through Time).

## Redes Neuronales Recurrentes (II)






# Long Short Term Memory (I)

- ▶ Una **unidad de memoria a largo-corto plazo (LSTM)** es una componente especializada, diseñada para retener información durante periodos de tiempo mas largos que las RNNs.
- ▶ Las LSTMs tienen varias puertas de control de la red.
- ▶ Estas unidades suelen estar formadas por:
  - Cell** Es la memoria de la unidad LSTM.
  - Input Gate** Controla la influencia de la nueva entrada en la celda.
  - Forget Gate** Controla cuánto se retiene un valor en la celda.
  - Output Gate** Controla cuánto se usa un valor en la celda para calcular la unidad de salida.
- ▶ Existen conexiones hacia dentro y hacia fuera de las puertas LSTM (algunos son recurrentes).
- ▶ Ventajas:
  - ▶ Los pesos de las puertas se aprenden durante el entrenamiento.
  - ▶ La red aprende qué patrón se debe retener.

## Long Short Term Memory (II)



Notebook

LSTM



Resumen

# Resumen (I)

## ► **Análisis** de la ST:

- Visualización.
- Análisis estadístico de los datos.
- Interpolación de huecos en la serie.
- Análisis de autocorrelaciones y autocorrelaciones parciales.

## ► **Predicción** de la ST:

- Dividir la serie en entrenamiento y test.
- Para buscar los hiperparámetros: búsqueda en rejilla sobre backtesting.
- Decidir el horizonte de predicción que nos interesa.

## Resumen (II)

- ▶ Modelos de predicción vistos:
  - ▶ Familia de modelos ARIMA:
    - ▶ **AR**: ST estacionarias
    - ▶ **MA**: ST estacionarias
    - ▶ **ARMA**: ST estacionarias
    - ▶ **ARIMA**: ST con tendencia
    - ▶ **SARIMA**: ST con tendencia y estacionalidad
    - ▶ **SARIMAX**: modelos anteriores con variables exógenas
  - ▶ Familia de modelos de suavizado exponencial:
    - ▶ **Suavizado exponencial simple**: ST estacionarias
    - ▶ **Suavizado exponencial doble**: ST con tendencia
    - ▶ **Holt-Winters suavizado exponencial**: ST con tendencia y estacionalidad
  - ▶ **LSTM**

# Predicción de Energías Renovables como Series Temporales

Ángela Fernández Pascual

---

**Gracias por vuestra atención.**